

SEMINÁRNÍ PRÁCE

ANALÝZA LETECKÝCH DAT

AUTOR 1: Marek Tatýrek (240456)

AUTOR 2: Albert Kindl (228632)

AUTOR 3: Mojmír Němec (229050)

ROČNÍK: 1

PŘEDMĚT: Business Intelligence

DATUM: 6. 3. 2026

Obsah

1	Úvod	1
2	Business otázky	1
	BQ1: Vliv dne v týdnu na spolehlivost	1
	BQ2: Vztah vzdálenosti a zpoždění	2
	BQ3: Schopnost dopravců kompenzovat zpoždění	2
	BQ4: Stabilita a volatilita výkonu v čase	2
3	Práce s metadaty	3
	a) Výběr atributů	3
	b) Vysvětlení významu klíčových atributů	3
	c) Omezení a specifika dat (a jejich ošetření)	4
4	Data audit a integrace	5
	Popis ETL logiky	5
	Data Quality & Cleaning Decisions	5
5	Interpretace a doporučení	6
	Hlavní zjištění	6
	Zjištění 1 (BQ1): Pátek je systematicky nejproblematictější dnem	6
	Zjištění 2 (BQ2): Střední lety trpí vyšší mírou zpoždění	7
	Zjištění 3 (BQ3): Rozdílná schopnost kompenzace	9
	Zjištění 4 (BQ4): Skrytá nestabilita výkonu v čase	9
	Konkrétní doporučení	10
	Limity analýzy	11
6	Závěr	11

1 Úvod

Tato semestrální práce se zaměřuje na analýzu spolehlivosti letecké dopravy v USA v období let 2022 až 2024. Jako primární zdroj slouží reálná provozní data z data-setu „On-Time Reporting Carrier On-Time Performance“ poskytovaná americkým ministerstvem dopravy (BTS). Zpracovávána je rozsáhlá datová sada pokrývající 36 měsíců provozu, která detailně mapuje průběh uskutečněných letů.

Hlavním cílem projektu je navrhnout, realizovat a interpretovat ucelené Business Intelligence řešení, které transformuje surová data na informace využitelné pro manažerské rozhodování. Práce systematicky aplikuje celý analytický proces: od detailního studia metadat a datového auditu, přes datové transformace, až po vizualizaci a interpretaci výsledků. Výstupem je zodpovězení čtyř konkrétních byznysových otázek, které zkoumají skryté trendy ve zpožděních, vliv vzdálenosti a schopnost jednotlivých dopravců kompenzovat časové ztráty. Na základě těchto zjištění jsou v závěru formulována praktická a adresná doporučení pro optimalizaci letištního provozu a plánování letových řádů.

2 Business otázky

Cílem této práce je odpovědět na následující business otázky zaměřené na spolehlivost letecké dopravy. Každá otázka byla formulována tak, aby byla striktně časově vymezená (roky 2022–2024), vázaná na konkrétní entity a měřitelná pomocí přesně definovaných KPI. Tím předcházíme obecným a analyticky neuchopitelným dotazům.

BQ1: Vliv dne v týdnu na spolehlivost

- **Otázka:** Jak se liší spolehlivost letů mezi jednotlivými dny v týdnu v období 2022–2024 a existují dny se systematicky vyšší mírou zpoždění?
- **Zkoumané entity:** `DayOfWeek` (den v týdnu), typ dne (pracovní vs. víkend).
- **Klíčové KPI:** `ArrDel15 Rate` (frekvence), `Avg ArrDelayMinutes` (intenzita).

Analyzujeme konkrétní kalendářní úsek ve vymezeném tříletém období. Spolehlivost neměříme pouze pocitově, ale rozdělili jsme ji na dvě oddělená KPI: pravděpodobnost, že let bude mít zpoždění nad 15 minut (`ArrDel15 Rate`), a průměrnou délku tohoto zpoždění v minutách. To nám umožňuje zjistit, zda v určité dny lety meškají častěji, nebo zda je zpoždění méně časté, ale o to masivnější.

BQ2: Vztah vzdálenosti a zpoždění

- **Otázka:** Existuje v období 2022–2024 vztah mezi délkou letu (vzdáleností) a mírou zpoždění příletu a jsou delší lety náchylnější ke zpoždění než krátké?
- **Zkoumané entity:** Kategorie vzdálenosti (krátký do 500 mil, střední, dlouhý).
- **Klíčové KPI:** ArrDel15 Rate, Avg ArrDelayMinutes, Median ArrDelayMinutes.

Otázka nezkoumá plošný „vliv vzdálenosti“, ale vyžaduje kategorizaci záznamů do přesných logických segmentů. Zásadním analytickým prvkem je zde doplnění průměru o medián (**Median ArrDelayMinutes**). Uvědomujeme si totiž silnou asymetrii dat u zpoždění letů (většina letů je včas, ale outliery sahají do stovek minut), kde by samotný průměr mohl vést k chybným závěrům o typické zákaznické zkušenosti.

BQ3: Schopnost dopravců kompenzovat zpoždění

- **Otázka:** Jaký je v období 2022–2024 vztah mezi zpožděním odletu a zpožděním příletu a do jaké míry jsou dopravci schopni zpoždění během letu kompenzovat?
- **Zkoumané entity:** Dopravce (**Reporting Airline**), let.
- **Klíčové KPI:** Avg DepDelayMinutes, Avg ArrDelayMinutes, Avg Delay Difference.

Ptáme se na konkrétní schopnost kompenzace (tzv. catch-up efekt během letu). Otázka je exaktně vázána na entitu dopravce a k jejímu zodpovězení jsme vytvořili vlastní odvozené KPI – rozdíl mezi příletovým a odletovým zpožděním (Delay Difference). Díky tomu nehodnotíme aerolinku jen podle toho, s jakým zpožděním letadlo přebírá, ale jak efektivně s ním dokáže ve vzduchu pracovat.

BQ4: Stabilita a volatilita výkonu v čase

- **Otázka:** Jak stabilní je výkon jednotlivých dopravců v čase (2022–2024) a dochází k výrazným výkyvům ve spolehlivosti mezi měsíci?
- **Zkoumané entity:** Dopravce (**Reporting Airline**), měsíc/rok.
- **Klíčové KPI:** ArrDel15 Rate, Avg ArrDelayMinutes, StdDev ArrDelayMinutes.

Otázka se nespokojuje s celkovým tříletým průměrem, který často maskuje sezónní extrémy, ale vyžaduje sledování trendu na měsíční granularitě. Kromě standardních KPI jsme do otázky záměrně integrovali měření směrodatné odchylky (`StdDev ArrDelayMinutes`). To nám umožňuje analyzovat volatilitu – identifikujeme tak dopravce, kteří například sice v celoročním průměru vypadají spolehlivě, ale v letních špičkách jejich systém fatálně selhává.

3 Práce s metadaty

Základním předpokladem pro zajištění metodické správnosti výpočtů KPI a zamezení logických chyb byla detailní analýza oficiálního datového slovníku. Neznalost metadat totiž vede k chybným výpočtům KPI a špatné interpretaci. V této kapitole je popsáno, jak jsme datový slovník aktivně využili k výběru atributů, jak interpretujeme jejich význam a jak jsme se vypořádali s datovými omezeními.

a) Výběr atributů

Při návrhu analytického modelu jsme nepostupovali „naslepo“, ale pro každou business otázku jsme z metadat záměrně vybrali ty atributy, které zaručují robustní výpočet:

- Pro identifikaci dopravce (BQ3, BQ4) jsme záměrně zvolili atribut `Reporting_Airline` (Unique Carrier Code). Slovník výslovně varuje, že IATA kódy mohou být v čase přiřazeny různým dopravcům a nejsou vždy unikátní, a proto je pro analýzu napříč lety (zde 2022–2024) nutné použít právě Unique Carrier Code.
- Pro výpočet průměrných zpoždění jsme zásadně nevyužívali ruční odčítání časových polí plánovaného a skutečného času (`CRS` vs. `Actual`), jak předepisuje metodika. Zvolili jsme přímo předpočítané metriky `DepDelayMinutes` a `ArrDelayMinutes`, abychom zamezili zkreslení.
- Pro sledování primárních příčin zpoždění (kategorizace v BQ2) jsme vybrali pole `CarrierDelay`, `WeatherDelay` či `LateAircraftDelay`, u kterých datový slovník jasně definuje, že hodnoty jsou v minutách.

b) Vysvětlení významu klíčových atributů

Atributy používané pro KPI jsme rozdělili na spojitě metriky a binární indikátory. U každého jsme museli zohlednit specifickou logiku jeho hodnot:

Metrika zpoždění (`ArrDelayMinutes/DepDelayMinutes`): Tato pole měří intenzitu zpoždění v minutách. Datový slovník striktně rozlišuje mezi standardními

poli „Delay“ a „DelayMinutes“. Zatímco pole `DepDelay/ArrDelay` nabývají i záporných hodnot v případě předčasného odletu či příletu, u polí s příponou „Minutes“ jsou tyto záporné (předčasné) odchylky automaticky ošetřeny a nastaveny na 0. V naší analýze jsme záměrně použili pole `DelayMinutes` pro výpočet průměru. Pokud bychom použili atributy se zápornými hodnotami, dopravce, který cíleně létá dříve, než plánoval, by matematicky „vymazal“ svá kritická zpoždění a průměr by neadekvátně klesl. Použitím „Minutes“ měříme pouze čistý negativní dopad na zákazníka.

Indikátor zpoždění (`ArrDel15`): Na rozdíl od výše uvedených metrik, které měří „jak moc“ se let zpozdil, `ArrDel15` je binární indikátor určující „zda vůbec“ let překročil toleranci 15 minut (1=Yes). V naší analýze jej používáme k segmentaci letů a výpočtu hlavního KPI `ArrDel15 Rate` (podíl zpožděných letů). Tento atribut eliminuje zkreslení outliers – let zpožděný o 16 minut má zde stejnou váhu jako let zpožděný o 5 hodin.

Kategorizační dimenze (`Distance` a `DayOfWeek`): `DayOfWeek` udává kalendářní kontext letu a slouží nám pro vytvoření vlastní dimenze Typ dne (Pracovní dny 1–5 vs. Víkend 6–7). `Distance` měří vzdálenost mezi letišti v mílech. V naší analýze pro BQ2 jsme tuto číselnou metriku využili ke klastrování do tří kategorií (krátké do 500 mil, střední do 1500 mil a dlouhé nad 1500 mil).

c) Omezení a specifika dat (a jejich ošetření)

Klíčovým úkolem z pohledu Business Intelligence bylo ošetřit záznamy, které za určitých podmínek nedávají smysl a při prostém výpočtu průměru nebo jiných metrik by znehodnotily výsledky. Analyzovali jsme následující omezení definovaná v metadatech:

Zrušené lety (`Cancelled = 1`): Datový slovník definuje indikátor zrušeného letu. Zásadním specifikem těchto záznamů je, že neobsahují validní skutečné časy a tudíž ani hodnoty zpoždění. Zrušené lety metodicky nepatří do KPI měřících zpoždění. Pokud bychom tyto lety neodfiltrovali, prázdné nebo nulové hodnoty v časech by zásadně zkreslily výpočet průměrného zpoždění pro BQ1 až BQ4. Na základě zjištění jsme pro účely měření času tyto záznamy před agregací zcela oddělili.

Odkloněné lety (`Diverted = 1`): Podobné specifikum platí pro odkloněné lety. Z metadat vyplývá, že u odkloněných letů zůstává standardní atribut `ArrDelay` jako NULL. Přestože tyto lety fyzicky odletěly, nedorazily do své plánované destinace, a proto pro ně nelze měřit standardní zpoždění příletu. V rámci datového auditu jsme vyřadili všechny záznamy s `Diverted=1` z operačního datasetu (`df_ops`). Zahnutí takových letů by buď způsobilo chybu ve výpočtu kvůli NULL hodnotám, nebo by v lepším případě uměle zmenšilo jmenovatel při výpočtu průměru.

Zkreslení silnou asymetrií dat zpoždění: Z povahy atributu `ArrDelayMinutes` vyplývá, že obrovské množství záznamů nabývá hodnoty 0 (včasné lety), zatímco část záznamů představuje extrémní výkyvy (zpoždění přesahující 500 minut kvůli kalamitám). Pokud se pro interpretaci spolehlivosti použije výhradně průměr (`Avg ArrDelay`), je hodnota silně pod vlivem outlierů a neodráží realitu typického letu. Z tohoto důvodu jsme se rozhodli v rámci BQ2 pracovat vedle průměru povinně i s mediánem a distribučním rozptylem, čímž jsme ošetřili interpretační zkreslení vyplývající ze statistické povahy dat.

4 Data audit a integrace

Popis ETL logiky

Zpracování 36 měsíčních souborů proběhlo programově v jazyce Python (knihovna `pandas`):

- Extract:** Hromadné načtení všech 36 CSV souborů z adresáře přes funkci `glob`. Byla provedena projekce pouze na relevantní sloupce pro minimalizaci paměťové náročnosti a ověřeno 100 % pokrytí let 2022–2024.
- Transform:** Filtrování uskutečněných letů (vyřazení `Cancelled=1` a `Diverted=1`). Odstranění nekompletních záznamů s `NULL` hodnotami u klíčových metrik (`ArrDelayMinutes`, `Distance`). Doplnění chybějících hodnot `ArrDel15`. Výpočet odvozených atributů: `DayType`, `DistanceCat`, `DelayDiff` a `YearMonth`.
- Load:** Výstupem je vyčištěný dataset operačních letů (`df_ops`) odeslaný pro výpočet KPI a vizualizace.

Data Quality & Cleaning Decisions

Problém / Zjištění	Řešení (Pravidlo)	Dopad na KPI	Zdůvodnění (vazba na metadata)
Datové typy sloupců	<code>low_memory=False</code> při načtení	Zamezení selhání výpočtů	Metadata definují typy; optimalizace brání false-positive konfliktům.
<code>Cancelled=1</code> (chybí časy)	Vyloučeny z delay KPI, separátní KPI	Zamezení zkreslení průměru	Metadata: u <code>Cancelled=1</code> nejsou pole <code>DelayMinutes</code> relevantní.

Problém / Zjištění	Řešení (Pravidlo)	Dopad na KPI	Zdůvodnění (vazba na metadata)
Diverted=1 (neúplné zpoždění)	Vyloučení z operačního datasetu	Zamezení zkreslení ArrDelay	Metadata: ArrDelayMinutes je pro přesměřované lety NULL.
NULL v ArrDelayMinutes	Řádky dropnuty z datasetu	Přesné průměry	Bez hodnoty nelze počítat žádné zpoždění.
ArrDel15 NULL	Doplněno logikou ArrDelayMinutes ≥ 15	Záchrana podhodnocení ArrDel15 Rate	Přímé odvození z oficiální definice ArrDel15.
Záporné DepDelayMinutes	Nejsou odstraněny (nastaveny na 0)	Relevantní pro BQ3 kompenzaci	DepDelayMinutes = 0 pro brzké odlety.
Extrémní outliery (>500 min)	Ponechány, sledován i medián	Zajištění robustnosti (BQ2)	Outliery jsou reálné kalamity, smazáním bychom zkreslili realitu.
Distance = NULL	Řádky dropnuty	Přesná kategorizace letů (BQ2)	Distance je povinný atribut.

5 Interpretace a doporučení


Hlavní zjištění

Zjištění 1 (BQ1): Pátek je systematicky nejproblematičtější dnem


Tvrzení: Pátek vykazuje systematicky nejvyšší hodnotu ArrDel15 Rate. Nadprůměrně často nabírají zpoždění také lety ve čtvrtek a v neděli. Naopak nejméně zpoždění nabírají lety v úterý a ve středu. Celoročně platí, že víkendové lety mají lehce vyšší podíl zpožděných letů. Výjimku tvoří měsíc květen, kdy je trend lehce opačný, a březen, kdy je podíl zpoždění víkendových letů výrazně vyšší než u všedních dnů. Víkendové statistiky zhoršují především nedělní lety; sobotní se pohybují kolem průměrné míry.

Důkaz: Viz obrázek 1 a obrázek 2. Provozní hustota na konci pracovního týdne kumuluje zpoždění, která se propagují přes celý systém.

Význam: Management by měl cílit opatření zejména na páteční, respektive víkendové spoje, nikoliv plošně na celý týden.



Obrázek 1: Míra zpoždění letu podle dne v týdnu



Obrázek 2: Rozdíl mezi víkendy a všedními dny v závislosti na měsíci


Zjištění 2 (BQ2): Střední lety trpí vyšší mírou zpoždění

Tvrzení: Střední a dlouhé lety (500–1 500 mi a > 1 500 mil) vykazují vyšší ArrDel15 Rate než krátké lety, přičemž relativní pořadí kategorií zůstává konzistentní po celý rok. Sezónnost je výrazná a jednotná napříč všemi kategoriemi: červenec představuje absolutní vrchol (Střední 28,8 %, Dlouhý 27,6 %, Krátký 25,0 %), říjen a listopad jsou nejklidnějšími měsíci s přibližně polovičními hodnotami, prosinec pak vykazuje sekundární nárůst vlivem svátečního provozu.


Důkaz: Viz obrázek 3 a obrázek 4.

Význam: Střední a dlouhé lety jsou prokazatelně méně spolehlivé než krátké. Při jejich hodnocení je však třeba volit správné metriky – průměr je zkreslený extrémními výpadky (stovky minut), medián je naopak nulový, protože většina letů přilétá včas. Ani jedna z těchto metrik tedy nevypovídá o typickém „špatném“ letu.

Vhodnější je sledovat například 90. percentil, který odřízne výjimečné kalamity a ukáže horní hranici běžného provozního zpoždění. Extrémní outliery zaslouží samostatnou pozornost – mívají jinou příčinu (počasí, technické výpadky) a vyžadují jiná opatření než standardní provozní zpoždění.



Obrázek 3: Míra zpoždění letů podle jejich délky




Obrázek 4: Sezónnost zpoždění pro různé délky letů

Zjištění 3 (BQ3): Rozdílná schopnost kompenzace

Tvrzení: Část dopravců systematicky kompenzuje zpoždění během letu (záporná hodnota Avg DelayDiff), zatímco jiní zpoždění průměrně zhoršují. Nejlépe si vedou aerolinky WN, které zpoždění průměrně stahují o 1,5 minuty. Na druhém konci spektra jsou aerolinky YX s nárůstem +1,3 minuty, avšak je důležité toto číslo zasadit do kontextu: YX mají nejnižší průměrné odletové zpoždění ze všech sledovaných dopravců (9,96 min) a i přes nárůst během letu patří jejich příletové zpoždění (11,30 min) k nejlepším. Negativní DelayDiff u YX tedy neindikuje celkovou nespolehlivost, ale spíše nižší schopnost využít letový čas ke kompenzaci – na rozdíl od WN nebo DL, kteří i s vyšším odletovým zpožděním část ztráty dohnají.

Důkaz: Viz obrázek 5.

Význam: Schopnost kompenzace je klíčovým indikátorem operační efektivity a kvality plánování letů jednotlivými aerolinkami. Manageri horších aerolinek by se měli inspirovat procesy v těch lepších.



Obrázek 5: Kompenzace zpoždění u různých dopravců


Zjištění 4 (BQ4): Skrytá nestabilita výkonu v čase

Tvrzení: Samotná frekvence zpoždění (ArrDel15 Rate) maskuje propastné rozdíly v provozní stabilitě jednotlivých dopravců. Například dopravce AA sice nepatří k nejhorším v četnosti zpoždění, ale vykazuje nejvyšší směrodatnou odchylku, což pro cestující i návazné spoje znamená obrovskou nepředvídatelnost. Naopak aerolinky jako DL nebo WN dokazují, že i při masivním objemu letů lze udržet konzistenci a nízké výkyvy ve zpožděních. Dopravci v pravém horním kvadrantu (např. F9, B6)

naopak selhávají v obou metrikách, neboť jejich lety meškají velmi často a zároveň s obrovskými časovými výkyvy. Pro objektivní hodnocení spolehlivosti linek je tedy kritické nespolehat pouze na průměr, ale sledovat právě směrodatnou odchylku, která odhaluje skutečnou provozní odolnost dopravce vůči krizím.

Důkaz: Viz obrázek 6.

Význam: Výběr strategických partnerů nesmí stát jen na průměru, ale i na schopnosti udržet konzistentní výkon.



Obrázek 6: Stabilita aerolinek

Konkrétní doporučení

- **Cílení na páteční rotace:** U dopravců s nejvyšší páteční ArrDel15 Rate přezkoumat plánování bufferů v páteční odpolední špičce. Snížení zpoždění v tento den zabrání dominovému efektu na celý víkend.
- **Změna metodiky reportingu:** Průměrné zpoždění doplnit o podmíněný průměr pouze pro zpožděné lety (`ArrDelayMinutes` > 0) a o 90. percentil. Bezpodmínečný medián je nevhodný – přesahuje-li podíl včasných letů 50 %, vychází nula a neposkytuje žádnou informaci. Podmíněný průměr naopak říká „když už let meškalo, o kolik to typicky bylo“, a 90. percentil ukáže horní hranici běžného zpoždění bez zkreslení výjimečnými kalamitami.

- **Audit letových řádů:** Dopravci s vysokou kladnou hodnotou Avg Delay-Diff by měli prověřit plánování turnaround časů a rotací, protože zpoždění systematicky nabírají, místo aby jej kompenzovali.
- **Nové metriky pro strategická partnerství:** Při výběru dopravce pro co-deshare preferovat stabilitu (nízká StdDev). Zahrnout StdDev jako standardní KPI do kvartálního hodnocení partnerů.

Limity analýzy

- **Absence externího kontextu:** Analýza nepracuje s daty o počasí a kapacitě vzdušného prostoru. Výkyvy v letních špičkách mohou být dány čistě externími faktory.
- **Průměry u asymetrických rozdělení:** Průměrné zpoždění je extrémně citlivé na ojedinělé technologické výpadky. Průměr nadhodnocuje reálný stav většiny letů.
- **Omezená kauzalita:** Zjištěné trendy jsou historické korelace, nikoliv absolutní kauzální vztahy.

6 Závěr

Tato práce prokázala, že hloubková analýza leteckých dat za roky 2022–2024 dokáže odhalit kritické neefektivity, které běžný reporting často přehlíží. Klíčovým zjištěním je potvrzení pátečních špiček jako hlavního zdroje řetězeného zpoždění a nutnost používat v reportingu také medián namísto samotného průměru, který je silně zkreslen extrémními hodnotami. Analýza stability (směrodatné odchylky) navíc odhalila, že někteří dopravci představují pro zákazníky vysoké riziko nepředvídatelnosti, i když jejich průměrné výsledky vypadají na první pohled přijatelně.

Na základě zjištění byla formulována čtyři konkrétní doporučení: cílení bufferů na páteční odpolední špičku, kde se zpoždění kaskádově šíří do celého víkendu; nahrazení průměrného zpoždění podmíněným průměrem a 90. percentilem pro přesnější KPI reporting; audit turnaround plánování u dopravců, kteří zpoždění během letu systematicky zhoršují; a zahrnutí směrodatné odchylky jako standardního KPI při hodnocení spolehlivosti partnerů. Projekt tak plně naplnil svůj cíl a potvrdil, že BI řešení postavené na precizní práci s metadaty a správné volbě KPI je nezbytným podkladem pro moderní manažerské rozhodování v letecké dopravě.