

PŘÍLOHA – Výklad k metadatům a validační pravidla (A + B)

Tento dokument slouží jako podpůrná příloha k semestrální práci (Business Intelligence & Data Analysis). Obsahuje (A) oficiální výklad k metadatům a (B) konkrétní validační pravidla pro část 2.3 (Data audit).

PŘÍLOHA A — Oficiální výklad k metadatům

A.1 Proč tato příloha existuje

Datový slovník (metadata) určuje význam polí, jejich jednotky a omezení použití. Neznalost metadat vede k typickým chybám: špatné výpočty KPI, míchání zrušených/odkloněných letů do zpoždění a interpretace minutových polí jako počtů letů. Tato příloha shrnuje nejdůležitější pravidla interpretace polí.

A.2 Skupiny polí a jejich správná interpretace

A.2.1 Časové atributy a datum letu

- Year, Quarter, Month, DayOfMonth, DayOfWeek: kalendářní kontext letu.
- FlightDate: datum letu (formát yyyymmdd).
- Doporučení: vytvořte časovou dimenzi a odvozujte z ní měsíce/týdny/sezónnost.

A.2.2 Plánované vs. skutečné časy (CRS vs Actual)

- CRSDepTime, CRSArrTime: plánované časy (local time, hhmm).
- DepTime, ArrTime: skutečné časy (local time, hhmm).
- DepTimeBlk, ArrTimeBlk: hodinové bloky (užitečné pro analýzu špiček).
- WheelsOff, WheelsOn: časy vzletu a dosednutí (hhmm).
- Důležitý princip: pro KPI zpoždění typicky nepoužívejte ruční odčítání hhmm polí; používejte přímo zpoždění v minutách.

A.2.3 Zpoždění: rozdíl mezi „Delay“ a „DelayMinutes“

- DepDelay / ArrDelay: rozdíl plán vs skutečnost v minutách; může být záporný (předčasný odlet/přílet).
- DepDelayMinutes / ArrDelayMinutes: záporné hodnoty jsou ošetřeny na 0.
- DepDel15 / ArrDel15: indikátor 15+ minut (1 = Yes).
- DepartureDelayGroups / ArrivalDelayGroups: intervaly zpoždění po 15 minutách.
- Doporučení pro KPI: průměrná zpoždění počítejte typicky z *DelayMinutes, aby předčasné odlety/přílety nezkreslovaly průměr.

A.2.4 Pozemní časy

- TaxiOut: doba pojíždění před odletem (minuty).
- TaxiIn: doba pojíždění po příletu (minuty).
- Pozemní časy často indikují kapacitní problémy a špičky letišť (bottleneck).

A.2.5 Příčiny zpoždění (minuty, nikoli počet letů)

- CarrierDelay, WeatherDelay, NASDelay, SecurityDelay, LateAircraftDelay jsou definovány jako „Delay, in Minutes“.
- Interpretace: jde o minutové příspěvky ke zpoždění podle kategorie.
- Doporučení: agregujte je v minutách a pro srovnání mezi dopravci/letišti zvažte normalizaci (např. na 1000 letů).

A.2.6 Zrušené lety (Cancelled)

- Cancelled: indikátor zrušeného letu (1 = Yes).
- CancellationCode: důvod zrušení.
- Praktický důsledek: zrušené lety obvykle nepatří do KPI zpoždění; řešte je samostatně jako KPI míry zrušení.

A.2.7 Odkloněné lety (Diverted) a pole Div*

Odkloněné lety (Diverted = 1) mají specifickou logiku vyplňování některých polí. Proto existují speciální pole začínající „Div“.

- Diverted: indikátor odkloněného letu (1 = Yes).
- Pro diverted lety standardní ArrDelay a ActualElapsedTime zůstávají NULL; místo toho se používají DivArrDelay a DivActualElapsedTime (pokud odkloněný let dorazil do plánované destinace).
- DivAirportLandings, DivReachedDest, DivDistance: souhrnná pole k odklonům.
- Div1...Div5: detailní sekce až pro pět odkloněných letišť (kód letiště, ID/SeqID, WheelsOn/Off, ground time, TailNum).
- Praktický důsledek: diverted lety analyzujte odděleně a nemíchejte je do standardních KPI příletových zpoždění založených na ArrDelay.

PŘÍLOHA B — Validační pravidla pro Data audit (část 2.3)

Níže uvedená pravidla slouží jako doporučený základ pro kontrolu kvality dat. Tým si vyberou přiměřený počet pravidel. **Počet validačních pravidel v části 2.3 musí odpovídat počtu hlavních KPI (min. 4).** Každé pravidlo musí být **explicitně navázáno na konkrétní KPI** a popisovat datový problém, jeho dopad na výpočet nebo interpretaci KPI a zvolené řešení.

Pokud jsou validační pravidla obecná, nejsou jasně navázána na KPI nebo neřeší dopad na výpočet či interpretaci, nebude minimální počet považován za splněný.

Typicky špatné:

- všechna pravidla jen o NULL hodnotách
- žádná vazba na KPI
- žádné rozhodnutí „co s tím“

B.1 Pravidla pro Diverted (odkloněné lety)

B.1.1 Povinná NULL pravidla pro standardní pole u diverted letů

PRAVIDLO D1 (dle metadat):

IF Diverted = 1 THEN ActualElapsedTime IS NULL

PRAVIDLO D2 (dle metadat):

IF Diverted = 1 THEN ArrDelay IS NULL

- Doporučená kontrola: spočítejte podíl řádků, kde Diverted=1 a zároveň ActualElapsedTime nebo ArrDelay není NULL → označte jako nekonzistenci.

B.1.2 Vazba DivReachedDest na DivActualElapsedTime a DivArrDelay

PRAVIDLO D3 (silné doporučení):

IF Diverted = 1 AND DivReachedDest = 1 THEN DivActualElapsedTime IS NOT NULL

PRAVIDLO D4 (silné doporučení):

IF Diverted = 1 AND DivReachedDest = 1 THEN DivArrDelay IS NOT NULL

B.1.3 Vazba DivDistance na DivReachedDest

PRAVIDLO D5 (dle metadat):

IF DivReachedDest = 1 THEN DivDistance = 0

PRAVIDLO D6 (logická kontrola):

IF DivReachedDest = 0 THEN DivDistance != 0 (typicky > 0)

B.1.4 Konzistence detailních odklonů (Div1–Div5)

PRAVIDLO D7 (doporučení):

IF Diverted = 1 THEN DivAirportLandings >= 1

PRAVIDLO D8 (doporučení):

IF DivAirportLandings >= 1 THEN Div1Airport IS NOT NULL

- Poznámka: detailní DivN pole nemusí být vždy plně vyplněná. V auditu uveďte, zda jsou Div1–Div5 v daném datasetu konzistentní a jak s tím pracujete.

B.2 Pravidla pro Cancelled (zrušené lety)

PRAVIDLO C1 (metodické doporučení pro KPI):

IF Cancelled = 1 THEN nezahrnuj do KPI zpoždění (ArrDelay/DepDelay); řeš samostatně jako Cancelled rate

PRAVIDLO C2 (doporučení):

IF Cancelled = 1 THEN CancellationCode IS NOT NULL

B.3 Pravidla pro zpoždění a indikátory

PRAVIDLO L1 (dle definice):

DepDelayMinutes >= 0 AND ArrDelayMinutes >= 0

PRAVIDLO L2 (doporučení pro konzistenci):

IF DepDelayMinutes >= 15 THEN DepDel15 = 1

IF ArrDelayMinutes >= 15 THEN ArrDel15 = 1

B.4 Jak pravidla použít v části 2.3 (Data audit)

1. Vyberte 6–10 pravidel z této přílohy (nebo doplňte vlastní).
2. Pro každé pravidlo uveďte: (a) počet porušení, (b) dopad na KPI, (c) zvolené řešení (filtr/oprava/oddělení).

3. Rozlišujte pravidla „dle metadat“ (např. D1, D2, D5, L1) a pravidla „auditní doporučení“ (např. D3, D4, D7, C2, L2).