


Projekt

Úkoly na 3 týden



✚ Co udělat v 3. týdnu

1 Definovat minimálně 4 business otázky

Každá otázka musí:

- mít časové vymezení (např. 2021–2024, meziročně, MoM, sezónnost...),
- být navázaná na konkrétní entitu (dopravce, letiště, time block...),
- obsahovat nebo implikovat konkrétní KPI,
- být formulovaná tak, aby byla jednoznačně zodpověditelná.

✗ Co nestačí:

- „Jaké jsou příčiny zpoždění?“
- „Jak se vyvíjí provoz?“

✓ Co se očekává

Například:

- „Jak se v období 2021–2024 změnil podíl letů se zpožděním ≥ 15 minut u dopravců s více než 50 000 lety ročně?“
- „Ve kterých časových blocích dochází k nejvyššímu podílu významných zpoždění a jak se tento podíl meziročně mění?“

🎯 Cíl prvního týdne

- Nepočítat KPI.
- Nedělat dashboard.
- Neřešit ETL.

👉 Cílem je správně nastavit analytický směr práce.

Pokud jsou otázky špatně definované, zbytek projektu nebude dávat smysl.

Check list aneb jak k tomu přistupovat

✅ Otevři 1–2 měsíční soubory

Zkontroluj:

- Kolik mají sloupců?
- Jsou názvy sloupců konzistentní mezi měsíci?
- Jaké jsou hlavní typy proměnných:
 - časové (Year, Month, CRSDepTime...)
 - výkonové (ArrDelayMinutes, DepDelayMinutes...)
 - indikátory (Cancelled, Diverted...)
 - segmentační (Carrier, Origin, Dest, TimeBlock...)

🎯 Cíl: vědět, *jaké entity a KPI lze vůbec formulovat.*



Check list aneb jak k tomu přistupovat

✓ Datový slovník (metadata)

Projdi jen klíčové atributy:

- Jak je definováno zpoždění?
- Rozdíl mezi plánovanými a skutečnými časy?
- Co znamená Cancelled = 1?
- Jsou delay hodnoty někdy záporné?
- Existují již předpočítané metriky (např. ArrDel15)?

🎯 Cíl: vyhnout se chybné interpretaci (např. počítat delay ze špatných polí).



Check list aneb jak k tomu přistupovat

✓ Rychlá základní kontrola dat

Bez hluboké analýzy zkontroluj:

1 Objem dat

- Kolik řádků má měsíc?
- Jsou některé měsíce výrazně jiné?

2 Cancelled & Diverted

- Přibližný podíl?
- Mají tyto záznamy chybějící časy?

3 Delay rozdělení

- Průměr vs. medián?
- Jsou extrémny (např. 500+ minut)?

🎯 Cíl: zjistit, zda jsou data „čistá“ nebo problematická.



Check list aneb jak k tomu přistupovat

✓ Časová dimenze

Zkontroluj:

- Pokrývají data skutečně celé 3 roky?
- Jsou všechny měsíce přítomny?
- Existují time blocks (hodinové bloky)?
- Je možné dělat:
 - MoM?
 - YoY?
 - sezónnost?

🎯 Cíl: ověřit, že lze formulovat časové KPI (min. 2 jsou povinné).



Check list aneb jak k tomu přistupovat

✓ Segmentační možnosti

Podívej se:

- Kolik je dopravců?
- Kolik letišť?
- Lze analyzovat:
 - dopravce × letiště?
 - time block × carrier?
 - route?

🎯 Cíl: zjistit, na jakou entitu navážeš business otázky.



Check list aneb jak k tomu přistupovat

✓ Rychlé poznámky pro otázky

Sepiš si:

- 2–3 věci, které tě překvapily
- 2–3 potenciální problémy (např. vysoký podíl Cancelled)
- 2 možné KPI, které dávají smysl

Např.:

- „Ranní špičky mají vyšší delay“
- „U některých dopravců je extrémní variabilita“
- „Cancelled mají prázdné delay → nutné oddělit“



Check list aneb jak k tomu přistupovat

🕒 Výstup po 60 minutách

Měl bys být schopen:

- říct, jaké jsou hlavní entity,
- vědět, jaké KPI dávají smysl,
- rozumět základním omezením,
- formulovat 4 kvalitní business otázky.

! Co v 1. týdnu NEDĚLAT

- ✗ detailní cleaning
- ✗ finální ETL
- ✗ složité modelování
- ✗ hledání kauzality

