

SEMESTRÁLNÍ PRÁCE (TÝMOVÁ, VOLBA NÁSTROJE)

Kontext zadání

Máte k dispozici **reálná provozní data letecké dopravy** za posledních **3 roky**:

- **Zdrojová data:**
 - 36 souborů ve formátu **Excel/CSV**
 - každý soubor = **1 měsíc provozu**
- **Metadata:**
 - samostatný **Word dokument** popisující význam všech atributů (datový slovník)

Vaším cílem je **navrhnout, realizovat a interpretovat BI řešení**, které umožní **manažerské rozhodování** na základě těchto dat.

Pro předměty

Business Intelligence & Bussiness analysis (Mgr.)

1. Organizační pravidla

- **Forma práce:** týmová
- **Velikost týmu:**
 - minimum **1 student**
 - maximum **3 studenti**
- **Volba nástroje:**
Každý tým si **zvolí jeden hlavní nástroj**:
 -  **Power BI**
 -  **SQL**

 Nástroj si **volíte sami**, ale:

- hodnocení je **rovnocenné**
 - důraz je na **myšlení, ne na nástroj**
-

2. Společné jádro práce (POVINNÉ PRO VŠECHNY TÝMY)

Bez ohledu na zvolený nástroj musí každá práce obsahovat:

2.1 Business otázky (min. 4, povinná konkretizace, ½-1 strana)

- otázky musí být:
 - časově vymezené
 - vázané na konkrétní entitu
 - spojené s KPI
- **obecné nebo opsané otázky nebudou uznány**

👉 Příklad konkretizace Business otázky (ilustrační příklad)

✗ Nevyhovující

„Jaké jsou příčiny zpoždění letů?“

☑ Vyhovující

„Jak se v období 2021–2024 změnil podíl zpoždění způsobených pozdním přiletem letadla u dopravců s více než 50 000 lety ročně a jaký to má dopad na spolehlivost přiletů?“

2.2 Práce s metadaty (1-2 strany)

- využití datového slovníku
- vysvětlení významu klíčových atributů
- popis omezení dat

Instrukce pro tento bod – rozšířené vysvětlení

Součástí zadání je **datový slovník (metadata)**, který popisuje význam jednotlivých atributů, jejich jednotky, logiku hodnot a omezení použití. Práce s metadaty je **povinnou a nedílnou součástí semestrální práce**.

Co se očekává

Prokázání, že **nepracujete s daty „naslepo“**, ale že rozumíte jejich významu a omezením. Nestačí pouze uvést, že metadata existují.

a) Aktivní využití datového slovníku

Tým:

- prokáže, že při analýze vycházel z oficiálního popisu atributů,
- identifikuje, které atributy jsou **klíčové pro zvolené business otázky**,
- vysvětlí, proč byly vybrány právě tyto atributy a ne jiné.

b) Vysvětlí význam klíčových atributů

U vybraných (klíčových) atributů musí tým:

- stručně vysvětlit **co atribut měří** (ne pouze přepsat název),
- uvést **jednotky a logiku hodnot** (např. rozdíl mezi indikátorem a metrikou),
- popsat, **jak je atribut použit v analýze** (např. pro výpočet KPI, segmentaci, filtraci).

👉 Očekává se **vlastní interpretace**, nikoli mechanický přepis definice z metadat.

c) Popsat omezení a specifika dat

Tým musí identifikovat a popsat **omezení vyplývající z metadat**, například:

- atributy, které dávají smysl pouze za určitých podmínek (např. jen pro nezrušené záznamy),
- atributy, které nelze kombinovat bez logické kontroly,
- případy, kdy hodnota může být nulová, chybějící nebo zkreslující.

Součástí této části musí být také vysvětlení:

- **jak tato omezení ovlivňují interpretaci výsledků**,
- jak s nimi student **prakticky pracoval v analýze** (např. filtrování, oddělení záznamů, úprava výpočtů).

Ilustrační příklad

Časová pole (CRS vs. skutečné časy)

✗ ŠPATNĚ

„Porovnávali jsme plánované a skutečné časy odletu a příletu.“

Proč je to špatně:

- není jasné, **která konkrétní pole** byla použita,
 - je ignorován rozdíl mezi plánovaným a skutečným časem v metadatech,
 - není řešena **časová granularita ani bloky času**.
-

SPRÁVNĚ

„Při analýze zpoždění jsme vycházeli z metadat, která rozlišují plánované časy (CRSDepTime, CRSArrTime) a skutečné časy (DepTime, ArrTime). Pro výpočet zpoždění jsme nepoužívali rozdíl těchto časů přímo, ale metriky DepDelayMinutes a ArrDelayMinutes, které již zohledňují specifika výpočtu a ošetření záporných hodnot.

Pro analýzu denních špiček jsme využili atributy DepTimeBlk a ArrTimeBlk, které seskupují časy do hodinových bloků. Díky tomu bylo možné porovnávat provozní zatížení v průběhu dne bez nutnosti řešit minutovou granularitu a chybějící časové údaje u některých záznamů.

Z metadat rovněž vyplývá, že u zrušených letů nejsou skutečné časy relevantní, proto byly tyto záznamy z časových analýz vyloučeny.“

Proč je to správně:

- rozlišuje se **plánovaný vs. skutečný čas**,
- pochopení, že existují **předpočítané metriky** a proč je použít,
- využití **časových bloků smysluplně**,
- respektování omezení dat u zrušených letů.

Smysl tohoto bodu

- zvýšit **správnost a důvěryhodnost analýzy**,
 - předejít chybným závěrům způsobeným nepochopením dat,
 - osvojit si práci s daty tak, jak se pracuje v reálné praxi Business Intelligence a Data Analysis.
-

2.3 Data audit a integrace (1-2 strany)

- sjednocení cca 36 měsíčních souborů
- popis ETL logiky
- zdůvodnění čištění dat

Co se očekává

Sjednocení 36 měsíčních souborů (integrace)

✗ ŠPATNĚ (vágní, neověřitelné)

„Soubory jsme sloučili do jedné tabulky a sjednotili jsme strukturu.“

Proč je to špatně:

- neříká *jak* soubory sloučili (podle čeho, v jakém pořadí, jak řešili rozdíly)
- neobsahuje kontrolu, že soubory mají stejné sloupce/typy
- chybí informace o tom, zda jsou všechna období pokryta (5 let × měsíce)

☑ SPRÁVNĚ (krátké, ale konkrétní)

„Všechny měsíční soubory jsme načetli hromadně z jedné složky a sloučili (append) do jedné tabulky. Z názvu souboru jsme odvodili `Year` a `Month` a ověřili jsme pokrytí všech 36 měsíců (kontrolní tabulka: počet řádků po měsících). Před sloučením jsme zvalidovali shodu schématu (seznam sloupců) a datové typy. Pokud se v některém měsíci vyskytl chybějící sloupec, doplnili jsme ho jako NULL a popsali dopad na analýzu.“

Proč je to správně:

- říká *jak* (hromadné načtení, append)
- říká *co kontrolovali* (pokrytí měsíců, shoda schématu)
- řeší odchylky (chybějící sloupec → NULL + dopad)

Popis ETL logiky (Extract–Transform–Load)

✗ ŠPATNĚ (ruční, nereprodukovatelné)

„Data jsme upravili v Excelu, některé hodnoty jsme smazali a pak jsme udělali grafy.“

Proč je to špatně:

- ruční úpravy bez popisu → nejde zopakovat
- není jasné, která pravidla byla použita a proč
- nelze auditovat správnost

☒ SPRÁVNĚ (stručné ETL, ale reprodukovatelné)

„ETL jsme popsali ve třech krocích:

Extract: automatické načtení všech souborů z adresáře a standardizace názvů sloupců.

Transform: převod datových typů, tvorba časových atributů (`Date`, `Year`, `Month`, `DayOfWeek`, `TimeBlock`), ošetření nekonzistencí dle metadat (např. zrušené lety).

Load: uložení do modelu (Power BI) / do DWH tabulek (SQL) / export 'gold datasetu' (Python) včetně datového slovníku výsledku.

Každý krok je dohledatelný (Power Query kroky / SQL skripty / notebook).“

Proč je to správně:

- jasná struktura ETL
- popisuje klíčové transformace (typy, časové dimenze)
- uvádí výstup a důkaz reprodukovatelnosti

Zdůvodnění čištění dat (cleaning decisions)

☒ ŠPATNĚ (nezdůvodněné zásahy)

„Odstranili jsme chybějící hodnoty a extrémní hodnoty, aby to vyšlo lépe.“

Proč je to špatně:

- žádný důvod ani pravidlo
- riziko zkreslení výsledků
- „aby to vyšlo“ je zásadně neobhájitelné

☒ SPRÁVNĚ (pravidla + dopad na KPI)

„Na základě metadat jsme nastavili pravidla čištění:

1. Záznamy `Cancelled = 1` jsme nevyužívali pro výpočty zpoždění, protože časové údaje a zpoždění nejsou u zrušených letů relevantní; místo toho jsme pro ně vytvořili samostatné KPI 'míra zrušení'.

2. Pro průměrné zpoždění jsme použili `DepDelayMinutes/ArrDelayMinutes`, aby předčasné odlety/přiletí nezkreslovaly průměr.
3. Outliery zpoždění jsme neodstranili plošně; porovnali jsme průměr a medián a u extrémů jsme uvedli, jak ovlivňují KPI.
Každé pravidlo jsme zdokumentovali v tabulce 'problém → dopad → řešení → důvod'."

Proč je to správně:

- jasná pravidla vycházející z metadat
- oddělení zrušených letů od zpoždění
- kontrola dopadu (průměr vs medián)
- auditovatelná dokumentace rozhodnutí

Tuto část je možné zpracovat do tabulky Problém → Dopad → Řešení → Zdůvodnění

Ukázka:

Oblast	Problém / zjištění	Dopad na analýzu	Pravidlo / řešení (co přesně dělám)	Zdůvodnění (vazba na metadata)	Kontrola (jak ověřím, že je to ok)
Integrace souborů	Některé měsíce mají odlišný datový typ sloupce (např. číslo jako text)	Chybné agregace, chyby při výpočtech KPI	V ETL vynucuji datové typy (date/int/float) a nevalidní hodnoty mapuji na NULL	Datový slovník definuje jednotky a typy; bez správných typů KPI nemá smysl	Po ETL kontrola: počet NULL po sloupcích + test agregací (sum/count)
Pokrytí období	Chybí jeden měsíc (soubor nebyl nahrán / načten)	Zkreslení trendů a YoY	Z ETL generuji seznam očekávaných měsíců a porovnám s načtenými; chybějící měsíc je explicitně uveden v reportu	Analýza „posledních 5 let“ vyžaduje úplné pokrytí	Kontrolní tabulka: počet záznamů po měsících + seznam chybějících období
Cancelled	U <code>Cancelled=1</code> jsou chybějící nebo nesmyslné časy a zpoždění	Průměrné zpoždění vychází zkresleně	Zpoždění počítám pouze pro <code>Cancelled=0</code> ; pro <code>Cancelled=1</code> mám samostatné KPI „míra zrušení“	Metadata říkají, že zrušené lety nemají smysluplné skutečné časy	Kontrola: porovnání počtu Cancelled a podílu NULL v time sloupcích

Je akceptována i kratší verze

Problém	Pravidlo	Dopad na KPI
Cancelled má prázdné časy	Delay KPI pouze pro Cancelled=0	Průměrné zpoždění nezkreslené
DepDelay může být záporné	KPI z DepDelayMinutes	„Early departures“ nezkreslují průměr
Outliery	průměr + medián	Transparentní interpretace

DŮLEŽITÉ

Součástí části 2.3 musí být tabulka *Data quality & cleaning decisions* s minimálně 8 položkami, kde každá položka obsahuje problém, dopad, pravidlo, zdůvodnění.

Je akceptována i tabulka *Data quality & cleaning decisions*, která **musí obsahovat minimálně tolik položek, kolik je definováno hlavních KPI (min. 4)**. Každá položka musí být **explicitně navázána na konkrétní KPI** a popisovat datový problém, jeho dopad na výpočet nebo interpretaci KPI a zvolené řešení.

2.4 Interpretace a doporučení (1-2 strany)

- shrnutí hlavních zjištění
- **konkrétní doporučení**
- limity analýzy

Co se očekává

Cílem je prokázat, že umíte převést výsledky analýzy do **srozumitelných závěrů pro rozhodování**. Nestačí jen popsat grafy nebo zopakovat „co je vidět“. V této části se hodnotí **interpretace, argumentace a praktická použitelnost**.

Shrnutí hlavních zjištění (co jsme zjistili a proč to je důležité)

Uveďte **minimálně 4 hlavní zjištění** (dle rozsahu zvolených KPI). Každé zjištění musí být:

- **konkrétní** (ne „existuje sezónnost“, ale *kdy a jak se projevuje*),
- **podložené výsledkem** (odkaz na KPI, graf, dotaz, vizualizaci),
- **interpretované** (co to znamená pro provoz/řízení, ne jen popis hodnot).

Doporučená forma pro každé zjištění (2–4 věty):

1. *Tvrzení*: co jsme zjistili
2. *Důkaz*: jaký ukazatel / kde v analýze to podporuje
3. *Význam*: proč je to důležité / koho to ovlivňuje

Pozn.: Vyhněte se „grafové turistice“ (popsat vše, co je vidět). Vyberte jen to, co je relevantní pro business otázky.

Konkrétní doporučení (co má management udělat)

Na základě zjištění navrhnete **minimálně 4 konkrétní doporučení**. Doporučení musí být:

- **akční** (něco se dá udělat),
- **adresované** (kdo to má udělat: dopravce/letišť/operations),
- **odůvodněné** (které zjištění k němu vede),
- pokud možno s **odhadovaným dopadem** (co se zlepší: KPI / riziko / náklady).

Doporučená forma pro každé doporučení (3–6 vět):

- *Doporučení*: co konkrétně změnit
- *Proč*: vazba na zjištění / KPI
- *Dopad*: očekávané zlepšení / riziko / trade-off
- *Realizace*: nástin jak (např. cílovat konkrétní segmenty, časové bloky, letiště)

Příklad špatně: „Zlepšit spolehlivost.“

Příklad dobře: „U dopravců s vysokým podílem LateAircraftDelay upravit plánování rotací a zvětšit buffer mezi lety v ranních špičkách; cílit na konkrétní time blocks a letiště.“

Limity analýzy (co může zkreslovat závěry a co chybí)

Tato část je povinná, protože v praxi BI/DA nikdy nejsou data dokonalá. Uveďte **minimálně 3 limity** a ke každému popište:

- *jaký má dopad na interpretaci*,
- *jak by se dal limit zmírnit* (např. doplnění dat, jiná metrika, robustní postup).

Limity mohou být například:

- neúplnost/omezení některých atributů (např. u určitých typů záznamů),

- chybějící externí kontext (počasí, kapacity letišť),
- použití průměrů u silně asymetrických rozdělení (outliery),
- omezená možnost kauzality (zjišťujeme vztahy, ne příčinné důkazy).

Pozn.: Limity nejsou „přiznání chyby“. Naopak zvyšují důvěryhodnost práce.

JAK INTERPRETOVAT

Cílem je převést výsledky analýzy do **rozhodovacích závěrů**. Nehodnotí se množství grafů, ale kvalita interpretace a vazba na KPI a business otázky.

Povinný obsah

1. **Hlavní zjištění – 4 zjištění** (ideálně 1 zjištění = 1 KPI)
 - ke každému zjištění uveďte:
 - (i) tvrzení, (ii) důkaz** (KPI/graf/tabulka), **(iii) význam** (pro rozhodování).
 - doporučená délka: **3–4 věty na zjištění**.
2. **Doporučení – min. 3 doporučení**
 - ke každému doporučení uveďte:
 - co udělat, komu, proč (vazba na zjištění/KPI), jak ověřit úspěch.**
 - doporučená délka: **3–5 vět na doporučení**.
3. **Limity analýzy – min. 3 limity**
 - u každého: **co omezuje, dopad na interpretaci, jak zmírnit.**
 - doporučená délka: **2–3 věty na limit**.

Ilustrační ukázka

1) ZJIŠTĚNÍ

✗ Špatně:

„Zpoždění se mění během roku a někdy roste.“

☑ Dobře (stručně):

„U KPI % ArrDel15 je vidět sezónnost: v některých měsících roste podíl 15+ zpoždění. Důkaz: trend ArrDel15 v čase. Pro management to znamená cílit opatření na sezónně riziková období, ne plošně.“

2) DOPORUČENÍ

✗ Špatně:

„Doporučujeme snížit zpoždění a lépe plánovat.“

☒ **Dobře (stručně):**

„Zavést větší buffer mezi rotacemi u segmentů s vysokým *LateAircraftDelay* v nejrizikovějších time blocích. Vazba: zjištění o podílu *LateAircraftDelay* na zpoždění. Úspěch ověřit poklesem *ArrDel15* a *ArrDelayMinutes* před/po v daných segmentech.“

3) LIMIT

☒ **Špatně:**

„Data nejsou dokonalá.“

☒ **Dobře (stručně):**

„Chybí externí kontext (např. detailní počasí/kapacita letišť), proto nelze vyvozovat kauzalitu, jen souvislosti. To může zkreslit interpretaci důvodů zpoždění. Zmírnění: doplnit externí data a validovat závěry na rozšířeném datasetu.“

3. NÁSTROJOVÉ VARIANTY (tým si vybere pouze jednu)

Společné pravidlo pro všechny varianty:

Každý tým musí definovat a implementovat **minimálně 4 KPI**, z toho **minimálně 2 KPI musí být časové** (např. trend v čase, YoY, MoM, rolling average, srovnání období).

KPI musí být navázány na business otázky a musí být jednoznačně definované (vzorec, filtry, jednotky, podmínky validity).

VARIANTA A — POWER BI (Business Intelligence)

Hlavní zaměření

- datový model (dimenzionální)
- DAX (KPI)
- dashboarding (manažerský report)

Povinné minimum

1. Datový model

- vytvořte **hvězdicový model** (min. **1 fakt + 3 dimenze**)
- povinná je **časová dimenze** (kalendářní tabulka) a korektní vztahy
- uveďte a obhajte **grain** faktové tabulky

2. KPI (min. 4, z toho min. 2 časové)

- implementujte **min. 4 KPI v DAX**
- **min. 2 KPI musí být časové**, např.: YoY, MoM, rolling 3M/6M, trend/indexace
- každé KPI musí mít krátkou definici v reportu (co měří, jednotky, filtry)

3. Dashboard / report (min. 3 stránky)

- **Stránka 1: Executive overview** – KPI + trendy (časová KPI musí být vidět)
- **Stránka 2: Analytický detail** – drill-down (dopravce/letišťe/time block)
- **Stránka 3: Metodika & kvalita dat** – stručně: zdroje, ETL logika, cleaning pravidla

Co musí být obhajitelné

- proč je model navržen takto (fakta/dimenze, grain, vztahy)
- proč jsou KPI definovaná právě takto (vazba na metadata a na business otázky)
- jak report odpovídá na business otázky (ideálně 1 KPI ↔ 1 otázka)

Bonus (volitelné)

- What-if parametr
 - Decomposition Tree / contribution analysis (Top N + Others)
 - pokročilá time intelligence (např. rolling s ošetřením nekompletních období)
-

VARIANTA B — SQL (BI / Data Warehouse)

Hlavní zaměření

- návrh datového modelu (DWH / hvězda)
- analytické dotazy
- kvalita dat a reprodukovatelnost

Povinné minimum

1. Datový model

- navrhnete **dimenzionální schéma** (DDL): min. 1 fakt + 3 dimenze
- definujete **grain** faktové tabulky a klíče (PK/FK)

2. ETL (reprodukovatelně)

- staging → transformace → načtení do fakt/dimenzí
- popište nebo doložte logiku čištění dat (skripty)

3. KPI (min. 4, z toho min. 2 časové)

- vytvořte **min. 4 KPI** jako SQL dotazy (nebo views),
- **min. 2 KPI musí být časové** (trend, YoY/MoM, rolling, srovnání období)

4. Analytické dotazy (min. 8 dotazů celkem)

- **4 dotazy = KPI** (jeden dotaz na každé KPI)
- **2 dotazy = časová analýza** (např. sezónnost, vývoj v čase, srovnání období)
- **1 dotaz = segmentace** (dopravce/letišťe/time block/route)
- **1 dotaz = kvalita dat** (např. Cancelled vs. delay, missingness, duplicity, outliers)

Pozn.: Dotazy mohou být i ve formě VIEW, ale musí být čitelné a zdokumentované.

Co musí být obhajitelné

- proč jsou odděleny fakta a dimenze (a proč je grain správný)
- jak ETL a cleaning ovlivnil KPI (konkrétní pravidla)
- proč jsou KPI dotazy navrženy takto (filtry, definice, jednotky)

Bonus (volitelné)

- window funkce (ranking, running totals, YoY bez subdotazů)
 - SQL testy kvality jako pravidla/validace
 - indexační strategie (stručně + zdůvodnění)
-

Doporučení (volitelné) — „KPI balíček“ pro všechny nástroje

1. **% významně zpožděných letů** (ArrDel15 rate) — časové KPI
2. **průměrné zpoždění příletu** (ArrDelayMinutes) — časové KPI
3. **míra zrušení** (Cancelled rate)
4. **podíl vybrané příčiny zpoždění** (např. LateAircraftDelay share)

(Týmy si mohou zvolit jiné KPI, ale musí splnit: 4 KPI, z toho 2 časové.)

4. CHECKLIST PRO TÝMY

Business otázky

- Každá otázka má časový rozsah
- Je definovaná entita
- Jsou uvedeny KPI
- Lze jednoznačně říct, zda byla otázka zodpovězena

Data

- Pracujeme s metadaty
- Popsali jsme čištění dat
- Je ETL reprodukovatelné

Výstupy

- Výstup odpovídá zvolenému nástroji
 - Závěry nejsou jen popisné
 - Doporučení jsou konkrétní
-

5. HODNOCENÍ (společné pro všechny varianty)

Oblast	Body
Business otázky & konkretizace	15
Práce s metadaty	10
Data audit & ETL	15
Nástrojová část (PBI / SQL / Python)	20
Analýza	20
Interpretace & doporučení	20
Bonus	+5
Celkem	100 (+5)

Pozn.: Velikost týmu **neovlivňuje bodový zisk**, ale očekává se odpovídající rozsah a kvalita.

Metodika přepočtu bodového hodnocení projektu

„Projekt je hodnocen na bodové škále 0–100 bodů. **Pro účely stanovení výsledného hodnocení v rámci předmětu je toto hodnocení převedeno lineární transformací na škálu 0–10 bodů.** Přepočet je proveden jako podíl celkového počtu dosažených bodů a hodnoty 10 (výsledné hodnocení = dosažené body / 10). Lineární převod zachovává vzájemné proporce mezi jednotlivými hodnoceními.“

6. Odevzdání

- report (PDF)
- nástrojový výstup (PBIX / SQL skripty)
- README (role členů týmu, struktura řešení)

7. Závěrečná poznámka pro studenty

Nástroj je jen prostředek. Hodnoceno je pochopení dat, kvalita otázek, analýza a schopnost vyvodit závěry.



Obrázek nezachycuje chaos. Zachycuje „nezanalýzovaná data“. Pokud vám obrázek dává smysl hned, pravděpodobně ještě nemáte hotovou interpretaci.

Jakákoliv podobnost s reálným průběhem semestrální práce je čistě náhodná. „Obecná konstatování typu ‚postačí jeden graf‘ či obdobně formulované návrhy nejsou v rámci tohoto předmětu považovány za finální řešení zadání. Jsou interpretovány jako formulace analytické hypotézy nebo návrhu postupu, který musí být dále metodicky rozpracován, realizován a interpretován v odpovídající analytické hloubce.“